

神经元看到了token 看不到的状态

具身场景下的异常警报

VLA · LIBERO-10 · 864 rollouts · 四个事先冻结的常数

手还在动,事情已经不对了——最早知道的,不是画面,也不是动作,
是模型深处的神经元。

向内探寻,向外进化 Seek within. Evolve beyond.

起点:一件旧事

内部状态知道的,比token 说出来的多。

- 推理大模型上的探针**NAD**:在多条候选答案之间,不读一个字,只凭神经元活动就能挑出更可能对的那条
- 把握与犹豫没有写进token,但内部状态里有


同一个思想换到具身场景——
VLA 大模型的内部,会不会也有类似的信号?

Chen et al., 2025 · Neuron Agreement Decoding · ICML 2026 Spotlight

现象:两条只差一条噪声的轨迹




✓ 两只壶先后上炉



✗ 悬在第二只壶上方

物理世界的trap 长什么样



固定同一初始状态,只变采样噪声,跑32 条:

14 成功 / **18 超时**

纵轴是**累计变化量**,不是到目标距离——

有的trap 就停在目标旁边

前半段同路:放好第一只壶(+13 cm),一起歇脚

分岔在第30 步:蓝色重新起跳;
橙色再也没涨过一厘米

世界还在被改变,曲线就还在涨。

为什么token / 动作侧难办

01 动作流照常输出

每个卡住的步,模型照样吐出幅值正常的10 帧动作

02 判决在终点


成功要等布尔判定翻真;而“长”两解——慢成功和快失败读起来一样

→ 得去别处看

悬停也好、打转也好,动作序列上读不出分类

▷ 口径提醒:动作侧**能**分成败(动作幅值 $t=30$ AUC 0.832), 但它读的是**任务阶段**而非卡住—— 详见防御页D1-D2。

神经元:pattern 与它的动力学



每个控制步,模型点亮一小撮神经元
4 个深层× 11 个动作token

先试了读身份(谁被点亮):**没用**
身份是场景指纹,换初始状态整套重排

有意义的是它的**动力学**:
顺利时随世界更迭,受困时更迭**变慢**

信号不在内容里,在流动里

金线t30 之后,右下角拉出水平条纹。实测:持久专家0.27/4,是换手速度降三分之一,不是完全冻结。

把凝固做成警报:三步

d_s 这一步挪了多远

相邻两步点亮集合的重叠距离
 $1 - |\cap|/|\cup|$, 平均成一个数

$r(t)$ 和自己比

除以自己开头**8**步: 只回答“我
比刚出发时慢了多少”


$\theta \cdot K$ 何时拉响

连续 **$K=3$** 步 $r(t) < 0.95 \rightarrow$ 报警。
四个常数在救援实验之前冻结

$$r(t) = \frac{W^{-1} \sum_{s=t-W+1}^t d_s}{W_0^{-1} \sum_{s=1}^{W_0} d_s}, \quad W = 4, \quad W_0 = 8$$

为什么要除以自己: 变化水位的方差**66.8%** 由场景决定 ($\eta^2=0.668$), 自归一扣掉的正是这67%。

相空间:三种命运



区域	对应
巡航	正常干活, $r \approx 1.0$
不动点	停滞类, $r \approx 0.45$
极限环	打转类, 一直在动

后期阻尼比实测:

停滞 $\zeta = 0.83$ vs 打转 $\zeta = 0.31$

同场景内AUC **0.651**

极限环那一族终态混进巡航区——
是漏报的主要来源

结果:抓住八成失败

81.2%


在线判对· 864 条

+19.7


高出多数类基线(61.5%)

80%

失败召回· 误报17%




判决矩阵:失败235 抓住184,成功117 误伤19



报警落点q18-q36,中位q28 —— 距超时还有一半路程

跨不同任务、不同初始状态;不看画面、不看动作、不看任务标签。

误报是什么




被误报的成功中位**41 步**,
安静的成功中位**37 步**

它们确实**更慢** —— 减速、擦着不动点的引力边缘,又自己爬回巡航区

警报读作“**正在下坠**”
而不是“必然坠毁”

这也是急救实验采用的读法

机制:不是模型坏了,是环锁死了



没有任何一个零件坏掉

模型正确响应了输入,物理也没错——
是复合映射有一个不是目标的不动点

为什么模型抓不到(policy_input 实证):

```
image (224,224,3)
wrist_image (224,224,3)
state (8,)
```

没有一个维度是时间。

三层障碍:①输入无历史($\pi 0$ /OpenVLA 类)②演示数据里没有失败(所有模仿学习)③卡住时历史窗口内全是同一帧

失效在语义层,不在动力学层


层	内容
动力学	$s' = f(s, a)$ 动作有没有产生预期的物理效果(能学)
语义	$\Delta\phi(s)$ 这个效果有没有让任务前进(需目标监督)

手臂照常移动**3.3 cm/chunk**,效率还高4.8%。
净/路程0.52,远高于随机游走0.29 ——
大跨度、有方向地做无用功。

失败rollout,卡住前→后	变化
指令幅值	-5.4%
末端路程	+10%
末端净位移	+7%
回转半径	+17%
执行效率(位移/指令)	+4.8%
任务进展	-100%

推论:所有只学 $p(s'|s, a)$ 的模型(世界模型/卡尔曼/逆动力学)在这类trap 里预测得非常准,新息 ≈ 0 。本项目卡尔曼实测0.69-0.71,输给基线0.799。

急救!! 报警那一步,做一下干预



q32 报警→ 冻结状态 → 只加一点干扰(大幅度改换采样噪声)→ 继续。其余一切不动。

救回	3 / 8
步数	52 步失败 → 8 步完成
时长	26.0 s → 3.9 s

边界(不藏):

- 另一初始状态0/8
- 随机时刻分叉同样3/8
- 按变化幅度挑候选选不出赢家

结论

- 1 具身失败在动作层不可见、在语义层发生、在神经元的更新速率上留下痕迹
- 2 四个事先冻结的常数→ 864 条rollout 判对**81.2%**, 一套阈值跨任务不重调
- 3 报警之后还来得及:26.0 s 的失败变成**3.9 s** 的成功

github.com/Cck123123/Robot-Whisper

防御页

Q&A 按需翻出——主动交代弱点

D1 “用动作幅值不就行了?”

检测器	t=20	t=25	t=30	t=35
动作幅值	0.638	0.622	0.832	0.748
MoE 路由	0.478	0.685	0.801	0.742
末端位移	0.564	0.656	0.795	0.763
仿真状态	0.688	0.761	0.761	0.736
模型输入状态	0.493	0.572	0.740	0.775

诚实回答:是的,动作幅值在t=30 上赢了。
但它赢在哪里—— 见D2。

场景×快照内分层配对AUC,置换检验;跨组池化一律不用。

D2 它是进度计,不是卡住检测器

量	失败组(卡住前→后)	成功组(开头→末段)	对trap 的 d
MoE 路由	-12.6%	-1.9%	0.67
动作幅值	-5.5%	+24.1%	0.03
模型输入状态	-67.2%	-26.1%	3.30
末端位移	-1.7%	+27.6%	-0.12

动作幅值的判别力八成来自“成功组末段猛干”(+24%), 不是“失败组卡住”(-5.5%)。
对trap 事件本身的效应量只有**0.03** 个标准差。

D3 时效:MoE 是最晚的

检测器	检出率	报警中位
动作幅值	89.8%	q29
仿真状态	85.5%	q25
末端位移	76.2%	q30
MoE 路由	56.2%	q31

“更早/ 更强”这两句话不能说。

等误报率 $\approx 15\%$ 、等机会窗口 t_{j37} 。

D4 那MoE 赢在哪:跨任务阈值迁移

在object/t00 标定到15% 误报,阈值原样搬到其余22 个任务:

检测器	误报飘移	搬家后误报	搬家后检出	判读
MoE 路由	8 点	0%	69%	可用
模型输入状态	24 点	10%	100%	可用,误报翻倍
动作幅值	100 点	2%	100%	一个任务全员误报
动作块变化	10 点	0%	7%	伪稳定—— 等于关了

动作幅值为什么会100%:

标定任务是单阶段抓取;goal/t03 是“开抽屉+放碗”两阶段—— 开头8 步慢速接近→ 自归一基线偏低→ 后半程全部越线

任务内最强(0.832)
+ 跨任务最脆(100 点)
同时成立。

D5 MoE 稳的原因:三重不变性

层	内容	谁有
① 归一化不变	集合重叠 $\in [0, 1]$,不是“多少米/多少弧度”	仅MoE
② 重编号不变	$ \cap / \cup $ 不认专家编号	仅MoE
③ 自身基线归一	除以自己开头8步(扣掉67% 场景方差)	所有检测器

MoE 换来的不是判别力,是“一次标定,到处能用”。

这个价值在单任务benchmark 上完全看不见,只在多任务/多本体部署时兑现。

D6 残差化:在外部量之外还剩什么

	AUC	p
路由(原始)	0.801	<0.0001
路由⊥ 模型输入状态	0.780	<0.0001
路由⊥ 输入+动作+仿真	0.619	0.046
模型输入状态⊥ 路由	0.688	<0.0001

相关(秩):

路由vs 输入状态 +0.208

几乎不共线

路由vs 动作幅值 +0.562

路由vs 仿真状态 +0.667

路由不是输入的线性影子,但与“世界在不在动”共线较多;
扣掉全部外部量后还剩**0.619**,刚过显著线。

D7 “试过别的切法吗?” —— 全部关闭

方向	规模	结果
组织方式暴力搜索	646 种	残差后全塌
聚合方式暴力搜索	13,494 种	时间聚合值0.109 AUC,信号选择 ≤ 2.5 点
马尔可夫/ MDP	390 格	路由链里没有trap 集
卡尔曼/ SSM	—	0.69–0.71,输给基线0.799
AR(2) 阻尼比 ζ	—	场景内0.40–0.49
14 项峰值特征	—	全零;唯一 $p < 0.05$ 者复现符号翻转
9 项峰差比(TPR 族)	—	全零
token 之间的分歧	—	0.472–0.543;效率靶子 $\rho = +0.001$

峰值族为什么必然失败:

连续摆幅比 D_2/D_1 中位**1.053**(不衰减),与白噪声分布重合(AUC 0.480)。没有瞬态,峰值法的前提不存在。

核心解释:

chunk 间变化率是**单一共享因子** —— 后块层与基线相关0.95–0.97。这个张量在“变化率”读法下只有一个自由度。

D8 零提前量,而且有因果解释

窗口	占失败段	AUC	p
前16 步	32%	0.537	0.48
前20 步	40%	0.519	0.73
前24 步	48%	0.461	0.46
前30 步	60%	0.236	<0.0001

信号在q24→q30 之间出现,而trap onset 正在q30。

世界: 可改变 — × 不可改变

观测: 在变 — × 不变

路由: 在换 — × 更新减慢

三者同时翻转。路由是观测的函数

→ 不可能比世界更早知道。

模型对自己卡住毫无觉察:

路由熵(信心) **-0.04%**

token 之间的分歧 **-0.5%**

top-4 概率质量 **+1.4%**

限制清单

1. 跨任务迁移只有一个标定源(object/t00);留一交叉尚未做
2. 失败样本稀少:HUB 成功率92–98%,仅6 个任务有 ≥ 3 条失败
3. 跨本体无数据:同一台Franka、同一checkpoint;“换机器人会崩”是量纲推论
4. 相位混杂:固定t 比较时成功组已走完 $\sim 80\%$ 、失败组 $\sim 60\%$, 所有统计量都部分在读进度
5. 重放不可逐位复现:模拟器快照不完整,干预实验引用存档首轮
6. 单任务场景下MoE 无优势:policy_state 更强($d=3.30$ vs 0.67)也更简单

协议:组内配对AUC 按配对数合并;置换检验1500–5000 次;跨组池化一律不用 —— 池化会把0.586 抬到0.86,读的是场景难度。