

Neurons See the State the Tokens Don't

具身智能的内生异常警报——从神经元激活读出机器人的“卡住”

Robot-Whisper


Institute of Trustworthy Embodied AI · Fudan University

1. 起点:从语言模型到具身
2. 具身的trap 长什么样
3. ①②神经元能看见并报出trap 吗
4. ③能救回吗:干预
5. 结论

起点:从语言模型到具身


起点:语言模型上的两个发现

① NAD:神经元比token 知道得多



- token 只是神经元活动的**低维投影**,投影会丢信息
- 不读一个字,凭激活模式就能挑出更可能对的答案
- 因而能在CoT 的**早期**就判断对错

② TAAR:长思维链会掉进trap



- 长CoT 会掉进**Thinking Trap**(89% 的失败):越想越深,根错不改
- 陷得越深越难出来:晚期**resample** 多次仍是错的
- **早期识别**到trap, **一次resample** 就跳出错误盆地

两件事合起来是一条链: **内部信号比输出丰富** → **陷进trap 出不来** → **早识别+ 重采样能逃出盆地**

①Chen et al., *Do LLMs Signal When They're Right? Evidence from Neuron Agreement (NAD)*. arXiv:2510.26277 · ICML 2026 Spotlight

②Chen et al., *Thinking Traps in Long Chain-of-Thought: A Measurable Study and Trap-Aware Adaptive Restart (TAAR)*. arXiv:2601.11940 · Findings of ACL 2026

那么具身呢?—— 把同一条链搬到VLA 上

	LLM 推理(NAD / TAAR)	VLA 具身(本报告)
轨迹	reasoning trace(token 流)	interaction trajectory(动作流)
内部信号	神经元激活(NAD)	神经元激活pattern(每步点亮哪些)
trap	Thinking Trap:越想越深,根错不改	物理trap:动作在动,任务不前进
干预	早识别+ resample 一段CoT	早识别+ 冻结状态、换噪声重跑 rollout

但具身更难

- 输出是连续动作块,没有“对不对”可核对
- 每步接收新观测,错误会改变物理世界
- 策略无记忆,连“我在重复”都不知道

于是问同样的三个问题

1. 内部信号是否同样比动作丰富? 看得见吗
2. trap 是否在神经元上留下痕迹? 能报警吗
3. 重采样能否跳出盆地? 能救回吗

预告答案:能感知,神经元看得见trap; 可泛化,一套阈值跨任务不重调; 能干预,报警步换条噪声就能救回。

具身的**trap** 长什么样

具身的trap:两条只差一条噪声的轨迹



✓ 两只壶先后上炉

38 步 · 18.6 s



× 悬在第二只壶上方

52 步 · 26.0 s · 超时


同一个模拟器状态,唯一的区别是扩散头的一条采样噪声。

右边掉进去之后20 多步再没爬出来,直到超时—— 陷进去,出不来。

而动作输出读起来一样正常:每一步照样吐出幅值正常的10 帧。

LLM 的Thinking Trap ↔ 这里

物理世界的trap 长什么样



固定同一初始状态,只变采样噪声,跑32 条:

14 成功 / **18 超时**

纵轴是**累计变化量**,不是到目标距离——

有的trap 就停在目标旁边

前半段同路:放好第一只壶(+13 cm),一起歇脚

分岔在第30 步:蓝色重新起跳;
橙色再也没涨过一厘米

世界还在被改变,曲线就还在涨。 掉进去的18 条,**没有一条自己爬出来** —— 这就是错误盆地。

不看模型内部也能检测trap —— 但要付三笔代价

代价一 仪器

要在外面建一条**反馈**:随时知道机械臂、物体在哪—— 位姿真值、动捕、逐任务标定。

仿真里免费,真机上多数场景拿不到。有了坐标确实最准(对卡住事件 $d=3.30$),但那是特权信息。

代价二 泛化

trap 的物理样子千差万别:悬停、打转、拿起又放下;场景与任务也千差万别。规则写给一种,就漏掉别的。

带量纲的阈值换任务就漂:动作幅值100 点、坐标24 点;两阶段任务全员误报。

代价三 滞后

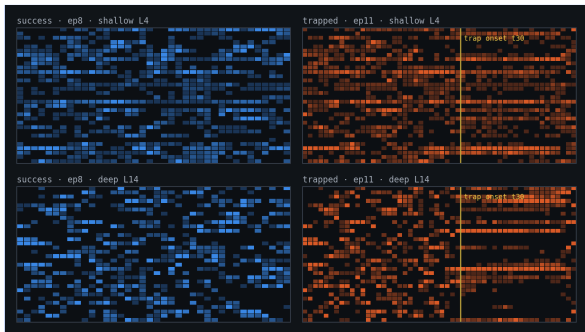
靠**形状**判定(数圈、计时)得等一圈闭合,或等过自然停顿才敢报。

成功轨迹放好第一只壶后自己也会歇十几步,第30 步才再起跳;计时窗口要盖过这段,报警就滑到q45 以后,而超时在q52。

能检测。但要**仪器**、**不泛化**、还**慢半拍** —— 我们想要的是:不加硬件、一套规则到处用、不等一圈闭合。

①②神经元能看见并报出**trap** 吗

神经元:pattern 与它的动力学



每个控制步,模型点亮一小撮神经元

激活pattern 本身就能定向感知trap:
受困后同一批神经元反复点亮成**水平条纹**;顺利时不断更换

再加上对**动力学**的理解,效果更好:
读更迭的**快慢**而非具体是谁,一套阈值跨场景、跨任务

pattern 负责感知,动力学负责泛化

警报只有一句话:换手速度比自己刚出发时慢,连续3步,就报。

图:同一初始状态的成功(蓝)与受困(橙)轨迹;上排浅层、下排深层;金线为trap 起点t30。越深的层,条纹越清楚。

结果:抓住八成失败

81.2%


在线判对· 864 条rollout

+19.7


高出多数类基线(61.5%)

80%

失败召回· 误报17%



判决矩阵· 存档批次352 条



跨不同任务、不同初始状态;不看画面、动作、任务标签。四个常数事先冻结,之后没有再调。

神经元怎么回应这三笔代价

回应一 零硬件

信号来自模型前向传播本身:每一步点亮哪些神经元,推理时顺手就有。不加传感器,不要坐标,不看画面。

回应二 特异性

世界里有千种卡法,模型里只有一种:环锁死,更新停转。停滞类塌到 $r \approx 0.45$ 的不动点;打转类多数也减速,少数一直在动,是漏报来源(召回80%)。

只读换手速度,不读身份(身份是场景指纹);无量纲,阈值搬22个任务只漂8点。


回应三 不等一圈

不需要看到trap的完整形状:连续3步(1.5 s)更新变慢就报。报警中位q28,距超时还有一半路程;报警步换一条噪声,3/8救回。

回答①:看得见——而且是免硬件、跨任务、不等一圈的那种看得见。

③能救回吗:干预

急救!! 报警那一步,做一下干预



q32 报警 → 冻结状态 → 只加一点干扰(大幅度改换采样噪声) → 继续。其余一切不动。

救回 3 / 8

步数 52 步失败 → 8 步完成

时长 26.0 s → 3.9 s

TAAR 的做法是按陷得深浅调重启力度(轻则重采样,重则强重启);我们只试了一种扰动——“陷得越深,扰动越强”是自然的下一步。

结论

结论:回到那三个问题

- ① 看得见吗 —— 看得见:同场景内AUC 0.80,而且**免硬件**、**一套阈值跨任务**(飘移8 点vs 100 点)、**不等一圈闭合**
- ② 能报警吗 —— 能:四个事先冻结的常数,864 条rollout 判对**81.2%**, 召回80%、误报17%
- ③ 能救回吗 —— 部分能:报警那一步换一条噪声,**3/8** 救回, 26.0 s 的失败变成3.9 s 的成功

具身与语言的差别,不在**能不能看见**,在**能不能提前**:神经元激活是观测的函数,不可能比世界更早知道。

github.com/Cck123123/Robot-Whisper

限制清单

1. 跨任务迁移只有一个标定源(object/t00);留一交叉尚未做
2. 失败样本稀少:HUB 成功率92–98%,仅6 个任务有 ≥ 3 条失败
3. 跨本体无数据:同一台Franka、同一checkpoint;“换机器人会崩”是量纲推论
4. 相位混杂:固定t 比较时成功组已走完 $\sim 80\%$ 、失败组 $\sim 60\%$, 所有统计量都部分在读进度
5. 重放不可逐位复现:模拟器快照不完整,干预实验引用存档首轮
6. 单任务场景下神经元信号无优势:policy_state 更强($d=3.30$ vs 0.67)也更简单

协议:组内配对AUC 按配对数合并;置换检验1500–5000 次;跨组池化一律不用 —— 池化会把0.586 抬到0.86,读的是场景难度。

防御页

Q&A 按需翻出

D1 “用动作幅值不就行了?”

检测器	t=20	t=25	t=30	t=35
动作幅值	0.638	0.622	0.832	0.748
神经元激活	0.478	0.685	0.801	0.742
末端位移	0.564	0.656	0.795	0.763
仿真状态	0.688	0.761	0.761	0.736
模型输入状态	0.493	0.572	0.740	0.775

诚实回答

是的,动作幅值在 $t=30$ 上赢了。 但它赢在哪里—— 见D2。

场景×快照内分层配对AUC,置换检验;跨组池化一律不用。

D2 它是进度计,不是卡住检测器

量	失败组(卡住前→后)	成功组(开头→末段)	对trap 的 d
神经元激活	-12.6%	-1.9%	0.67
动作幅值	-5.5%	+24.1%	0.03
模型输入状态	-67.2%	-26.1%	3.30
末端位移	-1.7%	+27.6%	-0.12

动作幅值的判别力八成来自“成功组末段猛干”(+24%), 不是“失败组卡住”(-5.5%)。
对trap 事件本身的效应量只有**0.03** 个标准差。

D3 时效:各检测器的报警时刻

检测器	检出率	报警中位
动作幅值	89.8%	q29
仿真状态	85.5%	q25
末端位移	76.2%	q30
神经元激活	56.2%	q31

“更早/ 更强”这两句话不能说。

等误报率 $\approx 15\%$ 、等机会窗口 t_{j37} 。

D4 那神经元赢在哪:跨任务阈值迁移

在object/t00 标定到15% 误报,阈值原样搬到其余22 个任务:

检测器	误报飘移	搬家后误报	搬家后检出	判读
神经元激活	8 点	0%	69%	可用
模型输入状态	24 点	10%	100%	可用,误报翻倍
动作幅值	100 点	2%	100%	一个任务全员误报
动作块变化	10 点	0%	7%	伪稳定—— 等于关了

动作幅值为什么会100%:

标定任务是单阶段抓取;goal/t03 是“开抽屉+放碗”两阶段—— 开头8 步慢速接近→ 自归一基线偏低→ 后半程全部越线

任务内最强(0.832)
+ 跨任务最脆(100 点)
同时成立。

D5 神经元信号稳的原因:三重不变性

层	内容	谁有
① 归一化不变	集合重叠 $\in [0, 1]$,不是“多少米/多少弧度”	仅神经元
② 重编号不变	$ n / u $ 不认神经元编号	仅神经元
③ 自身基线归一	除以自己开头8步(扣掉67% 场景方差)	所有检测器

神经元信号换来的不是判别力,是“一次标定,到处能用”。

这个价值在单任务benchmark 上完全看不见,只在多任务/多本体部署时兑现。

D6 残差化:在外部量之外还剩什么

	AUC	p
神经元激活(原始)	0.801	<0.0001
神经元激活 $\perp$ 模型输入状态	0.780	<0.0001
神经元激活 $\perp$ 输入+动作+仿真	0.619	0.046
模型输入状态 $\perp$ 神经元激活	0.688	<0.0001

相关(秩):

神经元vs 输入状态 +0.208

几乎不共线

神经元vs 动作幅值 +0.562

神经元vs 仿真状态 +0.667

神经元激活不是输入的线性影子,但与“世界在不在动”共线较多;
扣掉全部外部量后还剩**0.619**,刚过显著线。

D7 “试过别的切法吗?” —— 全部关闭

方向	规模	结果
组织方式暴力搜索	646 种	残差后全塌
聚合方式暴力搜索	13,494 种	时间聚合值0.109 AUC,信号选择 ≤ 2.5 点
马尔可夫/ MDP	390 格	激活序列的链里没有trap 集
卡尔曼/ SSM	—	0.69–0.71,输给基线0.799
AR(2) 阻尼比 ζ	—	场景内0.40–0.49
14 项峰值特征	—	全零;唯一 $p < 0.05$ 者复现符号翻转
9 项峰差比(TPR 族)	—	全零
token 之间的分歧	—	0.472–0.543;效率靶子 $\rho = +0.001$

峰值族为什么必然失败:

连续摆幅比 D_2/D_1 中位**1.053**(不衰减),与白噪声分布重合(AUC 0.480)。没有瞬态,峰值法的前提不存在。

核心解释:

chunk 间变化率是**单一共享因子** —— 后块层与基线相关0.95–0.97。这个张量在“变化率”读法下只有一个自由度。

D8 口径修正:blog 里三句话,这里怎么说

blog 原句	实测	这里的说法
动作流分不出“干活”与“打转”	动作幅值 $t=30$ AUC 0.832	动作侧 能 分成败,但读的是任务阶段;对trap事件效应量0.03
卡住→观测不变→输入不变	47 维仿真状态中19 维仍在变;末端位移保留99%	任务相关分量 停止更新——世界没停,是任务停了
同样的神经元反复点亮,思考冻结	持久点亮的神经元只是少数	换手速度 降 三分之一($\bar{d}$ 0.72 $\rightarrow$ 0.63),不是冻结

三处都主动改口径。对撞表放在这里,是把弱点变成可信度。

D9 零提前量,而且有因果解释

窗口	占失败段	AUC	p
前16 步	32%	0.537	0.48
前20 步	40%	0.519	0.73
前24 步	48%	0.461	0.46
前30 步	60%	0.236	<0.0001

信号在q24→q30 之间出现,而trap onset 正在q30。

世界: 可改变 — × 不可改变

观测: 在变 — × 不变

神经元: 在换 — × 更新减慢

三者同时翻转。神经元激活是观测的函数

→ 不可能比世界更早知道。


模型对自己卡住毫无觉察:

激活熵(信心) **-0.04%**

token 之间的分歧 **-0.5%**

被点亮神经元的概率质量 **+1.4%**

D10 Bad case:被误报的成功是什么样



被误报的成功中位**41 步**,
安静的成功中位**37 步**


它们确实**更慢** —— 减速、擦着不动点的引力边缘,又自己爬回巡航区

警报读作**“正在下坠”**
而不是**“必然坠毁”**

这也是急救实验采用的读法

阈值附近误报率随 θ 平滑变化,工作点不在断崖上;常数微调,结论不变。

谢谢! 扫码了解更多



项目网页

cckfdu.com/demo/robot-whisper




群聊: robot-whisper 交流群 1



该二维码 7 天内 (9 月 7 日前) 有效, 重新进入将更新

微信交流群

github.com/Cck123123/Robot-Whisper



QQ 交流群